



UNIVERSITÀ
DEGLI STUDI
FIRENZE

Da un secolo, oltre.



HR EXCELLENCE IN RESEARCH


Laboratorio di Image Processing and Security

Confronto di Modelli LLM per l'Espansione di
Prompt: Valutazione della Coerenza Semantica
tramite CLIP Score


Marco De Stefano

Obiettivi del Progetto:

1. Confrontare 4 modelli LLM open-source:
 - Mistral
 - Phi3
 - Llama3.2
 - Gemma2
2. Valutare la qualità delle espansioni tramite:
 - CLIP Score (coerenza semantica testo-immagine)
 - Tempo di risposta
3. Identificare il modello con:
 - Migliore coerenza semantica con immagini reali
 - Bilanciamento qualità/velocità
 - Potenziale applicabilità a sistemi text-to-image




Tempo di Risposta medio per ogni Query:



- Il modello phi3 è quello con tempo di risposta più lungo.
- Llama3.2 è il modello più veloce a rispondere alle query.
- modelli × 1000 classi × 3 prompt = 12.000 query

Numero di Classi per modello sotto la soglia globale




- Soglia globale calcolato sulla media dei clipscore di ogni modello e classe.
- Phi3 ha prestazioni più deludenti avendo la maggior parte delle classi sotto il threshold.
- Anche qui, llama3.2 ha ottimi risultati.


Distribuzione del ClipScore:

Da un secolo, oltre.


Distribution of Average CLIP Scores for llama3.2:latest




Distribution of Average CLIP Scores for gemma2:latest



Distribution of Average CLIP Scores for mistral:latest



Distribution of Average CLIP Scores for phi3:latest







Distribuzione del CLIP Score:

Osservazioni:

- Mistral: concentrato 0.6-0.7 (consistente)
- Phi3: picco 0.4-0.5 (sotto-performante)
- Gemma2: distribuito 0.5-0.7 (medio)
- Llama3.2: picco 0.6-0.7 con coda verso 0.8 (migliore)

- Score più alti = maggiore coerenza semantica

Distibuzione Cumulativa



Distribuzione Cumulativa:

- **Asse X:** soglia CLIP Score Asse
- **Asse Y:** numero classi con score $\leq$ soglia
- **Interpretazione:**
 - Phi3: curva alta (molte classi con score medio-bassi)
 - Llama3.2 e Mistral: curve basse (poche classi con score bassi)
- **Esempio:** alla soglia 0.6:
 - Phi3: ~950 classi sotto (male)
 - Llama3.2: ~270 classi sotto (bene)
- Vediamo, però, che phi3 è "safe" ma "boring", nel senso che allucina meno degli altri ma fa descrizioni troppo generiche rispetto agli altri modelli.



Sviluppi Futuri

- Performance:
 - ✓ Parallelizzazione delle query ai modelli LLM
 - ✓ Ottimizzazione gestione memoria GPU
- Qualità Output:
 - ✓ Controllo temperatura per output più concisi
 - ✓ Post-processing con NLP per selezionare frasi rilevanti
 - ✓ Specifica esplicita lunghezza nel prompt
- Esplorazione:
 - ✓ Modelli più potenti (es. DeepSeek-R1)
 - ✓ Varianti CLIP con limite token > 77

Conclusioni

- Llama3.2: Modello Raccomandato - Miglior CLIP Score medio (0.6-0.7) - Più veloce (0.5s/query) - Solo 24% classi sotto soglia - Ottimo bilanciamento qualità/velocità
- Ranking Finale:
 1. Llama3.2 (migliore)
 2. Mistral (buono, più lento)
 3. Gemma2 (medio)
 4. Phi3 (non consigliato per questo task)